7 Dars

SFT dan DPO gacha.

Base Modelni özbekchaga yoki soxaga moslab
Yaxshi javob beradigan modelga aylantirish.

Spec → Eval → SFT → Preference(DPO)
→ Safety → Serving → Deploy.

SFT modelga savol → ideal javob
juftliklarini körsatib öqitish.

LORA → modelni özini muzlatib,
faqat kichik qöshimcha qatlam (adapter)
öqitish.

QLoRA → LoRA, lekin asosiy model 4-bit
siqilgan holda xotira kam ketadi.

Pipline qoidasi: baholash

Eval öqitishdan oldin tayyorlanadi.

Avval taom qanday bölishi kerak yoziladi Spe,
tatib körish eval
Ustoz namuna beradi SFT
Ikki taomdan qaysi biri yaxshi DPO

LORA qalin kitobga yopishqoq qogʻozlarga izoh yozish. Kitob ōzgarmaydi faqat izohlar ōgitiladi.

QLORA kitobning ixcham nusxasi

SFT dan keyin nima chiqdi.

SFT ni ōgitdik natija 0.5B modelda 32/68.

Data yomon + Model kichik + Base Model

SFT bilim qōshmaydi.

SFT javob shaklini ōrgatadi. Yangi bilim qōshmaydi.

Evaluation baxolash notōgʻri bōlsa yaxshilanishni ōlchab bōlmaydi.

Yechim til va toza fugash tekshiruvni qōlda baxolash yoki LLM judge (kuchli LLM)

Qanday yaxshilaymiz?

1. Kattaroq Model 0.5 → 1,5B 32/68 → 44/68
2. Toza Data
3. Tōgʻri sozlama 5 → 3 Chunki 2 epohadan [illegible]

Halol baxolash va PPO

Nega DPO dan Oldin kuchli SFT kerak:

DPO faqat o'z javoblari orasida yaxshisini tanlaydi

Ikkala javob ham noto'g'ri bo'lsa, tanlash uchun yaxshi javob yo'q.

Preference data SFT modelidan olinadi, SFT zaif bo'lsa data ham zaif

DPO bilim bermaydi faqat xulqni yaxshilaydi.

DPO nima.

SFT dan keyin ham muammolar bo'ladi. noto'g'ri javob. Juda uzun javob noto'g'ri rad etish

Sabab SFT modelga faqat yaxshi namuna ko'rsatadi. Yomon javob bilan solishtirmaydi

Bir savolga esa ko'p javob to'g'ri kelishi mumkin.

Modelga 2 ta javobdan qaysi biri yaxshiroq ekanini tanlashni o'rgatadi.

Data	SFT Prompt + bitta ideal javob	Prompt + chosen + rejected
o'rgatadi	Nima deyish kerak [illegible]	Qaysi javob afzal
Bosqich	1-bosqich	2-bosqich (SFT dan keyin

Base Model → SFT → Preference data → DPO → Baholash.

DPO qanday o'rganadi.

2ta extimolli solishtiradi.

$$L_{DPO} = -\log\sigma\left(\beta\log\frac{\pi_\theta\, y_w(x)}{\pi_{ref}\, y_w|x}\right) - \beta\log\frac{\pi_\theta(y_l|x}{\pi_{ref}\, y_l}$$

Base model policy va frozen SFT reference.

Chosen javobning ehtimolligi rejected nisbatan oshiriladi.

Preference data va DPO pipeline

Preference data: har bir prompt uchun 2ta javoblar iborat. Chosen va rejected.

SFT data esa faqat prompt + bitta javob

4 qadamli pipline

1. Promt yaratish test savollarini 2 (4, 1ta)
2. Javoblar generatsiyasi SFT modelidan.
har promt uchun bir nechta javob (v1 4-ta)
3. Qoidalar bilan belgilash chosen/rejected.
4. DPO o'qitish — DPO loss bilan,
reference bir marta hisoblanadi boshlang'ich loss = 0,693 bo'ladi.