8-Dars

DPO ni rivojlantirish.

V2 ning mohiyati ikki qismdan iborat.

(a) preference juftliklarning (chosen / rejected) sifatini oshirish

(b) öqitishni SFT özgatgan narsani buzmaydigan qilish.

DPO pipeline

build-data → train.

SFT – DPO tartib bir xil

farq. DPO da javoblardan juftlik pair tuzatiladi. va xar bir javobga score beriladi A / B tanlov.

öqituvchi (SFT) model bitta savolga birnechta xil javob yaratadi.

Tekshiruvchi eng yaxshini ila eng yomoni ajratadi. DPO aynan shu farqdan öрганади.

DPO v1 ning kamchiliklari

Buzuq rad javob

Uzunlik bo'yicha xolis emaslik

Zaif ro'yxat tekshiruvi

Deyarli bir xil juftliklar saqlanardi.

Noto'g'ri til tekshiruvi

Javoblar soni kam.

Trail muammosi

V2 da o'zgarish.

Yuqoridagilar barchasi kuchaytirilgan.

Evalation eng yaxshi epoch faqat DPO loss bo'yicha edi

V2 da DPO+SFT loss bo'yicha tanlandi.

Learning rate ancha kichik bo'ldi

DPO tayyor SFT adapteridan davom etadi. katta qadamlar SFT o'rgatganini buzishi mumkin.

SFT va DPO

bir xil encode va bir xil train mexanizmi

Farqlar

Dataset → Savol + 1 ta tōg'ri javob
Savol (prompt + chosen + Rejected),
Loss function → Shu javob extimolligi oshiri
Chosen ↑ rejected ↓
Boshlang'ich nuqta → Yangi bōs LoRA,
train qilingan SFT adapter (undan davomi)
Reference → Yōq
SFT ehtimolliklar, traindan oldi holati,
Learning rate 2e-4 → 5e-6

Data Set tuzulishi.

SFT → har bir namuna savol va 1 ta javob,
role = user (savol/content) role = assistant (javob ca)
Model faqat assistant qismini ōrganu
DPO bitta savol va 2 ta javob (chosen va rejected)