10 Dars.

RLHF: Reward Model va PPO

Pretraining -> SFT -> LORA/QLORA -> DPO -> RLHF

SFT -> model instruction response namunalaridan javob berishni o'rganadi. Loss: Cross Entropy.

LORA/QLORA -> kam parametr yangilab FT.

QLORA = 4 bit base Model + LoRA Adapter.

DPO -> Chosen/Rejected juftliklari orqali modelni bevosita optimallash tizolik.

SFT dan keyin DPO ni boshladik. Aligment bosqichiga kirgan edik. Aligment bitta algoritm emas balki modelni inson xohishlariga moslashtirish jarayoni.

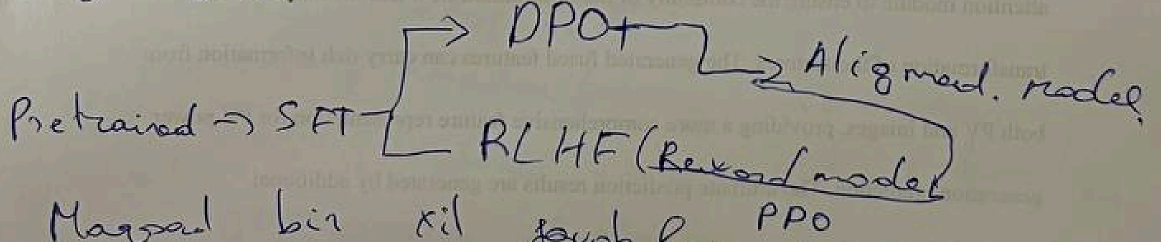

Maqsad bir xil javoblarni inson afzalliklariga

DPOdan keyin PPO qilish shart emas bular mustaqil yo'llar lekin ikkalasini bilish PT dunyoni tushunish uchun.

Pretraining kitoblar, hujjatlar, DB, serverlar ⇒ NN

SFT inson tayyorlagan instruction response juftliklar

Alignment → model xatti xarakatini to'g'rilash.

RLHF nima?

Inson fikri asosida mustahkamlovchi o'rganish. Model 2ta javob yaratadi. Inson yaxshirog'ini tanlaydi. Bu tanlov modelni yaxshilash uchun signalga aylanadi.

HF ⇒ Preference ⇒ Reward → Policy Optimizat.

1. Insonning javoblar haqidagi bahosi.
2. Preference bir javobni boshqasidan afzalligi.
3. Reward javob sifatini bildiruvchi sonli signal.
4. Policy Optimization ⇒ Javob strategiyasi yaxshilash.

Nega SFT yetarli Emas?

{ "instruction" : "Explain AI"
"response" : "Machine learning is a branch ....."

Model to'g'ri tokenga yuqori ehtimol berishga intiladi

SFT asosiy cheklovi:

Javob uzunligi. Ikkalasi xam to'g'ri lekin ko'pchilik foydalanuvchilar uzun javobni foydali oladi.
Bu farqni preference signal ushlaydi.

SFT faqat bitta toʻgʻri javobni takrorlashni oʻrgatadi. Barcha mumkin javoblar ichida qaysi biri yaxshiroq ekanini oʻrgatmaydi.

SFT namunalarda oʻqitiladi.

RLHF esa afzalliklaridan foydalanadi.

Cross Entropyda har bir namuna toʻgʻri deb olinadi. A dan B yaxshiroq degan taqqoslar loss ichida yoʻq

	SFT vs	RLHF
Nimadan foydalanadi	Instruction + Response namunalari	Inson afzalliklari yoki baholash
Nimani oʻrgatadi.	Qanday javob berish.	Javoblarni afzallarga moslashtirish
Loss	Cross Entropy	Murakkab pipeline Reward + RL optimi.
Murakkabli	Oddiyroq	PPO bilan murak.

SFT → RLHF → DPO 2018 → 2024.

1. Pretrained model next token prediction.
2. SFT Instruction Response. Inson tayyorlagan namunalar asosida koʻrsatmaga javob berish.

Amma SFT javobi har doim ham insonlar uchun eng yaxshisi boʻlavermaydi..

RLHF Model javobini insonlar afzalliklariga moslashtiradi

1 What is RLHF and what are its main stages?

RLHF →
SFT → Model → Human Preference Data yig'ish →
Reward model ōqitish → PPO bilan optimallash

2 RLHF aligns a model with human preferences start from an SFT model collect human preference comparisons.

1. RLHF nima qanday bosqichlardan iborat?

Modelni inson afzal ko'rgan javobga moslashtiradi.

1. SFT modelga tayyor savol → to'g'ri javob misollarini. ōrgatadi
2. Preference data bir savolga 2ta javob olinadi Inson ulardan yaxshisini tanlaydi.
3. Reward ~~data~~ Model: Inson tanloviga javobga ball qo'yishni ōrganadi.
4. PPO: model ball oshadigan tomonga ōqitiladi. KL penalty esa uni SFT holatidan uzoqlashtiradi.

2. Choosen Regected nima?

Inson afzal ko'rgani chosen (y_w) (x, y_w, y_l)
Kamroq yoqqani rejected (y_1)

3. Reward model nima?

RM savol va javobni oladi va bitta son qaytaradi. PPO ōsha balldan mukofot signal sifatida foydalanadi. RM ōzi javob yozmaydi faqat baholaydi.

4. ~~Bra~~ Bradley-Terry loss nima? Nega faqat ballari farqi muxim?

$$L = -\log \sigma(r_w - r_l)$$

5. PPO nega clipped objective ishlatiladi?

PPO yangi va eski policy extimollari nisbati hisoblaydi va uni $1-\varepsilon, 1+\varepsilon$ oraligida kesadi. odatda $\varepsilon = 0{,}2$ yani nisbat 0,8-1.2 oraligida bōladi. shunda model bitta yangilashda keskin ōzgarmaydi

6. Reference Model va KL penalty nima uchun kerak

Reference Model SFT modelining muzlatilgan nusxasi.

KL penalty $\beta \cdot D\_KL(\pi\_\theta \| \pi\_ref)$ model referencedan uzoqlashsa shunda jarima beradi. Bu til sifatini saqlaydi reward hackingni kamaytiradi..

7. PPO va DPO da GPU xotirasida nechta model turadi?

PPO 4ta model

1. Policy 2. Reference 3. Reward Model
4. Value Model

DPO 2ta model: Policy va Reference.

Shuning PPO ancha qimmat.

8. Reward hacking nima? Misol va 2ta chora.

Model RM ning zaif tomonini topib ballni oshiradi lekin xaqiqiy sifat oshmaydi

Katta qoy β (kuchliroq KL bog'ichi)

RM ni yaxshiroq va xilma-xil data bilan o'qit

9. Qachon DPO, qachon PPO?

DPO resurs kam, tayyor statik preference datasetda, soddalik va barqarorlik kerak.

PPO model yangi javob lar yaratib ular darhol baholanishi kerak.

Mukofotni onlayn xisoblaydi

Mezon bir nechta.

bitta RM ko'p marta ishlatiladi.