Post training

Pretraining ⇒ SFT ⇒ Aligment (DPO yoki RLHF: Reward Model + PPO /RLOO) ⇒ Chat Bot

1. Base Model "kōp ōqigan, lekin suxbatdosh emas.

- Internetd trillionlab tokenlarda ōqigan, keyingi token bashorat qila oladi
- U savolga javob bermaydi. Matn davom ettiradi.

↓

SFT.

Namunalar ōrganish ⇒ Modelga minglab instruction ⇒ response juftliklari kōrsatiladi. Data datalar JSON formatida bōladi va chat shabloniga ōraladi.

Loss: Cross Entropy

$$L_{SFT} = \Sigma_t \log P_\theta(y_t | x, y_{<t})$$

Loss faqat javob tokenlari bōyicha xisoblanadi. Savol qismi maskalanadi. Model foydalanuvchi savolini emas javobni yozishni ōrganadi.

SFT faqat bitta tōgri javobni takrorlashni ōrgatadi. Ikki tōgri javobdan qaysi biri yakshiroq ekanini bilmaydi.

Foydalanuvchi boshqa javobni tanlashi mumkin. Bu farqni SFT ushlay olmaydi. Shuning uchun Alignment kerak.

Qanday ōqitamiz, Full fine tuning LORA, QLORA.

Full FT ⇒ Modelning barcha weightlari qayta tuning

LORA ⇒ Asosiy weightlar muzlatiladi yoniga kichik 2ta matrix qoshiladi $W' = W + BA$
rank r kichik.

QLORA ⇒ Base Model 4 Bitga siqiladi. ustiga LORA adapter ōqitiladi.

Alignment nima?

Algoritm emas, balki modelni inson xohishiga moslashtirish jarayoni, foydali halole va zararsiz. bōlishi 2ta yoli bor.

1. DPO Pretrained → SFT ⇒ Preference Data ⇒ ⇒ DPO ⇒ Aligned Model

2. RLHF: Pretrained ⇒ SFT ⇒ Reward Model ⇒ PPO/RLOO ⇒ Aligned Model

Ikkala yŏl xam biz datadan boshlanadi

x, y_w, y_l

DPO ⇒ tŏg'ridan tŏg'ri tanlovlardan ŏrganadi

Reward modelxam, RL xam kerak emas

Model chosen ehtimolligini oshiradi

Rejected javob ehtimolligini kamaytiradi.

Reference modeldan (SFT) juda uzoqlashmaydi.

Sodda barqaror SFTga ŏxshab ŏqitiladi

offline → faqat tayyor juftliklardan ŏrganadi

RLHF

Policy (SFT) → javob yozadi va Baholardan ŏrganadi

Reward Model → javobga bitta son ball qŏyadi

RL Algoritmi (PPO yoki RLOO) baholardan qanday ŏrganish qoidasi.

SFT bilan RLHF farqi

SFT da model tayyor tŏg'ri javobni kŏchirib ŏrganadi

RLHF model ŏz javobini yozadi va hakam qŏygan balldan ŏrganadi.

PPO (Proximal Policy Optimization)

Murabbiyli ōqish.

PPO OpenAI 2017

InstructedGPT va ChatGPT

Savol Bu javob oʻtilganidan yaxshimi yoki yomon?

Policy + Reference + Reward + Value(critic).

PPO GPU↑

Prompt → Policy javob yozadi → Reward Model baholaydi → KL: Reference bilan taqqoslash → Advantage (Value Model GEL) → Clipped PPO update → takrorlash.

RLOO

Reinforce Leave One Out) murabbiysiz guruh bilan solishtirish.

1. Har bir promptga k ta javob yoziladi.
1. bizda k=4. Har bir javobning advantage: ōz ball minus qolgan 3ta javob ballari ōrtachasini oladi.

Critic yoq. Xotirada 3 ta model turadi. Policy, reference reward

KL jarimasi va clipping yangilab PPO dagidek qoladi.

Bir savolga 4 ta javob
6, 4, 5, 9 oldi

9 ballik javob uchun qolganlarining o'rtach.
(6+4+5)/3 = 5 Advantage = +4

4 ballik savol uchun. (6+5+9)/3 = 6,62
Model bunday javobni kamroq yozadi,

RPO vs RLOO

Advantage manbai	critic value GAE	shu promptda boshqa k-1 javob.
Advantage darajasi	har bir token.	butun javob uchun.
Xotiradagi model	4 ta (policy, ref, reward, value)	3 ta (policy, ref reward).
Bir vaqtda train model	2 ta policy va critic	1 ta policy
Generatsiya turi.	har promptda bitta javob	har promptda k ta javob.
Soddaligi	murakkab ko'p giperpar	soddi.

Qachon RLOO yaxshiroq.

reward faqat javob oxirida berilgan

GPU ↓

promtlar xarxil ularning ŏrtada bali farql.

harcom foaliyati model bo'lsa, critic baholay uchun asosan yoki RLOO ≥ PPO

SFT → Qanday javob berishni + instruction response + cross entropy + kofilcologi mah ≤ + × odob.

1 Base Bilim beradi, SFT xulq beradi, Aligmen odob beradi.

2. LORA QLORA kamlanga GPU

3. DPO aligment eng sodda yo'l ko'p ko'llaniladi, yaxshi preference data bo'lsa DPO yet.

4. RLHF (Reward model) qanday yaxshiroq. Shundalik yaxshi ishlay, Reward algoritm < Data, Reward model muhim.

5. PPO + RLOO advantageni hisoblaydi.

6. KL jarima, model SFT da ŏrgangan foydali xususiyatlarni uoblah tirama.